



TRƯỜNG ĐẠI HỌC NGOẠI NGỮ - TIN HỌC THÀNH PHỐ HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO KẾT THÚC HỌC PHẦN
HỌC MÁY

DỰ ĐOÁN GIÁ NHÀ BẰNG LINEAR REGRESSION

Giảng viên hướng dẫn: ThS. Huỳnh Thành Lộc

Sinh viên thực hiện:

- | | |
|---------------------|------------|
| 1. Phan Hoài Huy | 24DH190313 |
| 2. Mai Thị Ngọc Lam | 24DH190093 |

Thành phố Hồ Chí Minh, tháng 8 năm 2026



TRƯỜNG ĐẠI HỌC NGOẠI NGỮ - TIN HỌC THÀNH PHỐ HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO KẾT THÚC HỌC PHẦN
HỌC MÁY

DỰ ĐOÁN GIÁ NHÀ BẰNG LINEAR REGRESSION

Mã lớp học phần: 253123018402

Năm học: 2025 – 2026

Học kỳ: 3

Sinh viên thực hiện:

- | | |
|---------------------|------------|
| 1. Phan Hoài Huy | 24DH190313 |
| 2. Mai Thị Ngọc Lam | 24DH190093 |

Thành phố Hồ Chí Minh, tháng 8 năm 2026

LỜI CẢM ƠN

Chúng em xin gửi lời cảm ơn chân thành đến ThS. Huỳnh Thành Lộc, người đã trực tiếp hướng dẫn, định hướng và đóng góp nhiều ý kiến quý báu trong suốt quá trình thực hiện đề tài.

Chúng em cũng xin cảm ơn các bạn trong lớp đã hỗ trợ, trao đổi kiến thức và kinh nghiệm giúp chúng em hoàn thành bài báo cáo này.

Do kiến thức và thời gian có hạn, bài báo cáo không tránh khỏi những thiếu sót. Chúng em rất mong nhận được sự góp ý từ quý Thầy Cô để hoàn thiện hơn.

MỤC LỤC

LỜI CẢM ƠN.....	1
DANH MỤC HÌNH.....	4
DANH MỤC BẢNG	5
CHƯƠNG 1. GIỚI THIỆU.....	6
1.1. Đặt vấn đề.....	6
1.2. Mục tiêu của đề tài.....	6
1.3. Phạm vi nghiên cứu	6
1.4. Cấu trúc báo cáo	7
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT	9
2.1. Tổng quan về Học máy.....	9
2.2. Bài toán Hồi quy.....	9
2.2.1. Định nghĩa bài toán Hồi quy	9
2.2.2. Các thuật toán điển hình.....	9
2.2.3. Thước đo đánh giá.....	10
2.3. Các nghiên cứu liên quan.....	10
CHƯƠNG 3. CHUẨN BỊ DỮ LIỆU	11
3.1. Giới thiệu tập dữ liệu	11
3.2. Khám phá dữ liệu (EDA).....	Error! Bookmark not defined.
3.3. Tiền xử lý dữ liệu.....	13
3.4. Xây dựng đặc trưng	13
CHƯƠNG 4. XÂY DỰNG MÔ HÌNH.....	14
4.1. Giới thiệu mô hình.....	14
4.2. Quy trình huấn luyện mô hình	14
4.3. Ví dụ minh họa từng bước quy trình huấn luyện mô hình	14
4.4. Mô hình tự cài đặt.....	14
4.5. Mô hình cài đặt bằng thư viện	15
CHƯƠNG 5. THỰC NGHIỆM VÀ ĐÁNH GIÁ	16
5.1. Kết quả huấn luyện	16
5.2. Nhận xét.....	16

CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	17
6.1. Kết quả đạt được	17
6.2. Hạn chế của đề tài	Error! Bookmark not defined.
6.3. Hướng phát triển trong tương lai	18
TÀI LIỆU THAM KHẢO	19
PHỤ LỤC A. MÃ NGUỒN CHƯƠNG TRÌNH.....	A-1
PHỤ LỤC B. PHÂN CÔNG CÔNG VIỆC	B-1

DANH MỤC HÌNH

Hình 3.2. Heatmap ma trận tương quan giữa các đặc trưng	12
Hình 3.1. Biểu đồ Histogram/Boxplot cho phân phối giá nhà.....	13

DANH MỤC BẢNG

Bảng 3.1. Thông tin chi tiết các thuộc tính.....	11
Bảng 3.2. Thống kê mô tả dữ liệu	12
Bảng 5.1. Kết quả model Linear Regression ban đầu	16
Bảng B-1. Phân công công việc của các thành viên trong nhóm	B-1

CHƯƠNG 1. GIỚI THIỆU

1.1. Đặt vấn đề

Trong bối cảnh nền kinh tế và thị trường bất động sản ngày càng phát triển, dữ liệu liên quan đến nhà ở gia tăng nhanh chóng cả về khối lượng lẫn độ phức tạp. Việc định giá và dự đoán giá nhà một cách chính xác mang ý nghĩa đặc biệt quan trọng đối với người mua, người bán, các nhà đầu tư cũng như các tổ chức tài chính. Tuy nhiên, giá trị của một bất động sản không đứng độc lập mà chịu sự chi phối của hàng loạt yếu tố đa dạng như: vị trí địa lý, mức thu nhập trung bình của dân cư khu vực, tuổi thọ căn nhà, hay diện tích và số lượng phòng ở.

Học máy (Machine Learning) cung cấp các công cụ mạnh mẽ để khai thác các mẫu ẩn trong dữ liệu lịch sử nhằm đưa ra dự đoán. Dù hiện nay có rất nhiều thuật toán Học máy phức tạp, Hồi quy tuyến tính (Linear Regression) vẫn luôn được xem là nền tảng cốt lõi nhờ ưu điểm vượt trội về tính diễn giải (interpretability). Thuật toán này không chỉ giúp dự đoán một giá trị cụ thể mà còn chỉ ra rõ ràng mức độ và chiều hướng tác động (tăng/giảm) của từng yếu tố độc lập lên giá nhà [5],[8].

Từ những lý do trên, đề tài "Xây dựng hệ thống dự đoán giá nhà Việt Nam bằng Linear Regression" được thực hiện nhằm xây dựng một hệ thống dự đoán giá nhà dựa trên dataset Vietnam Housing Dataset 2024 và giao diện tương tác trực quan.

1.2. Mục tiêu của đề tài

Mục tiêu tổng quát:

Nghiên cứu cơ sở lý thuyết và ứng dụng thực tiễn của mô hình Hồi quy tuyến tính (Linear Regression) trong việc phân tích và dự đoán giá trị bất động sản, sử dụng bộ dữ liệu Vietnam Housing Dataset 2024.

Các mục tiêu cụ thể bao gồm:

- Phân tích và tiền xử lý dữ liệu: Thực hiện Khám phá dữ liệu (EDA) để hiểu rõ phân phối và độ tương quan giữa các đặc trưng (đặc biệt là mối quan hệ tuyến tính với giá nhà).
- Xây dựng và huấn luyện mô hình: Cài đặt thuật toán Hồi quy tuyến tính đa biến (Multiple Linear Regression) và các biến thể có hiệu chỉnh (Ridge Regression,

Lasso Regression) nhằm khắc phục hiện tượng quá khớp (overfitting) hoặc đa cộng tuyến.

- Đánh giá và phân tích trọng số: Đánh giá độ chính xác của mô hình thông qua các thước đo (RMSE, R^2 , MAE). Đồng thời, trích xuất và phân tích các hệ số hồi quy (Coefficients) để xác định xem yếu tố nào (như thu nhập, vị trí...) có tác động mạnh mẽ nhất đến giá nhà.
- Ứng dụng trực quan hóa: Xây dựng giao diện ứng dụng bằng Streamlit cho phép người dùng nhập các thông số đầu vào và nhận kết quả dự đoán giá nhà một cách trực quan, nhanh chóng.

1.3. Phạm vi nghiên cứu

Đề tài được giới hạn và tập trung nghiên cứu trong các phạm vi sau:

Về bộ dữ liệu: Sử dụng bộ dữ liệu Vietnam Housing Dataset 2024 được thu thập từ Batdongsan.vn và công bố trên Kaggle năm 2024. Dữ liệu chứa các thuộc tính mô tả bất động sản, trạng thái pháp lý, nội thất và giá nhà, rất phù hợp cho bài toán dự đoán giá nhà thực tế.

Về thuật toán Học máy: Đề tài giới hạn trong phạm vi các bài toán Học có giám sát (Supervised Learning) dạng Hồi quy (Regression). Cụ thể, nghiên cứu chuyên sâu vào họ các mô hình tuyến tính, bao gồm:

- Hồi quy tuyến tính cơ bản (Linear Regression - OLS).
- Hồi quy tuyến tính với chuẩn hóa L2 (Ridge Regression).
- Hồi quy tuyến tính với chuẩn hóa L1 (Lasso Regression).

Về giới hạn mô hình: Đề tài mang tính chất nghiên cứu nền tảng, cố ý không sử dụng các mô hình học phi tuyến phức tạp (như Cây quyết định, Random Forest, hoặc Học sâu) để tập trung làm rõ ưu, nhược điểm và giới hạn của việc giả định dữ liệu có mối quan hệ tuyến tính. Hệ thống được xây dựng trên môi trường máy tính cá nhân phục vụ mục đích học tập và nghiên cứu học thuật.

1.4. Cấu trúc báo cáo

Báo cáo gồm 6 chương:

- Chương 1: Giới thiệu - Trình bày tổng quan về đề tài, mục tiêu và phạm vi nghiên cứu.
- Chương 2: Cơ sở lý thuyết - Trình bày các kiến thức nền tảng về Học máy và các thuật toán.

CHƯƠNG 1. GIỚI THIỆU

- Chương 3: Chuẩn bị dữ liệu - Mô tả bộ dữ liệu, phân tích EDA và tiền xử lý.
- Chương 4: Xây dựng mô hình - Trình bày quy trình huấn luyện và cài đặt.
- Chương 5: Thực nghiệm và đánh giá - So sánh kết quả các thuật toán.
- Chương 6: Kết luận và hướng phát triển - Tổng kết và đề xuất hướng phát triển.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1. Tổng quan về Học máy

Học máy (Machine Learning) là một lĩnh vực của Trí tuệ nhân tạo tập trung vào việc phát triển các thuật toán cho phép máy tính học từ dữ liệu và đưa ra dự đoán hoặc quyết định mà không cần được lập trình cụ thể [4], [8].

Phân loại Học máy:

- Học có giám sát (Supervised Learning): Dữ liệu có nhãn, mục tiêu là học ánh xạ từ đầu vào đến đầu ra.
- Học không giám sát (Unsupervised Learning): Dữ liệu không có nhãn, mục tiêu là tìm cấu trúc ẩn trong dữ liệu.
- Học tăng cường (Reinforcement Learning): Học thông qua tương tác với môi trường.

Trong đề tài này, chúng tôi tập trung vào bài toán Học có giám sát dạng Hồi quy.

2.2. Bài toán Hồi quy/Phân lớp/Gom cụm

2.2.1. Định nghĩa bài toán Hồi quy

Hồi quy (Regression) là bài toán dự đoán một giá trị số liên tục dựa trên các đặc trưng đầu vào. Cho tập dữ liệu $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ với x_i là vector đặc trưng và y_i là giá trị mục tiêu, mục tiêu của bài toán là tìm hàm $f: X \rightarrow Y$ sao cho $f(x) \approx y$ [4].

Trong đề tài, mục tiêu là dự đoán giá nhà (Price) dựa trên các đặc trưng đầu vào của dataset Vietnam Housing Dataset 2024.

2.2.2. Các thuật toán điển hình

Các thuật toán Hồi quy được sử dụng trong đề tài:

a) Linear Regression

Linear Regression là mô hình tuyến tính đơn giản nhất, giả định mối quan hệ tuyến tính giữa các đặc trưng và giá trị mục tiêu:

$$y = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n.$$

CHƯƠNG 2. CỞ SỞ LÝ THUYẾT

Linear Regression học các hệ số w bằng cách tối thiểu hóa tổng bình phương sai số giữa giá trị thực và giá trị dự đoán. Đây là mô hình phổ biến trong bài toán hồi quy vì dễ triển khai, dễ hiểu và cho phép diễn giải ảnh hưởng của từng đặc trưng đến kết quả dự đoán.

b) Ridge Regression (L2)

Ridge Regression là biến thể của Linear Regression với regularization L2[4], thêm thành phần $\alpha \sum w_i^2$ vào hàm mất mát để tránh overfitting và xử lý đa cộng tuyến.

c) Lasso Regression (L1)

Lasso Regression sử dụng regularization L1 với thành phần $\alpha \sum |w_i|$ [4], có khả năng đưa các hệ số của đặc trưng không quan trọng về 0, thực hiện tự động chọn đặc trưng.

2.2.3. Thước đo đánh giá

Các thước đo được sử dụng để đánh giá mô hình Hồi quy[4]:

- RMSE (Root Mean Squared Error): $\sqrt{(1/n \times \sum (y_i - \hat{y}_i)^2)}$ - Đo sai số dự đoán, cùng đơn vị với target.
- R^2 (R-squared, Coefficient of Determination): $1 - \sum (y_i - \hat{y}_i)^2 / \sum (y_i - \bar{y})^2$ - Đo tỷ lệ phương sai của target được giải thích bởi mô hình.
- MAE (Mean Absolute Error): $1/n \times \sum |y_i - \hat{y}_i|$ - Đo sai số tuyệt đối trung bình.

2.3. Các nghiên cứu liên quan

Bài toán dự đoán giá nhà đã được nhiều nhà nghiên cứu quan tâm. Các nghiên cứu điển hình:

- Sử dụng Hồi quy tuyến tính để dự đoán giá nhà tại Boston (Harrison và Rubinfeld, 1978) [1].
- Ứng dụng Random Forest trong dự đoán giá bất động sản (Antipov và Pokrovskaia, 2017) [6].
- So sánh hiệu suất các thuật toán Machine Learning trong dự đoán giá nhà (Truong và cộng sự, 2020) [5], [8].
- Nghiên cứu về Gradient Boosting cho bài toán hồi quy bất động sản (Mullainathan và Spiess, 2017) [7].

CHƯƠNG 3. CHUẨN BỊ DỮ LIỆU

3.1. Giới thiệu tập dữ liệu

Bộ dữ liệu Vietnam Housing Dataset 2024 được thu thập từ Batdongsan.vn và được công bố trên Kaggle năm 2024. Dữ liệu bao gồm nhiều mẫu bất động sản Việt Nam với các thuộc tính mô tả diện tích, mặt tiền, hướng nhà, tình trạng pháp lý, nội thất,... và biến mục tiêu là price.

Thông tin chi tiết các thuộc tính:

Bảng 3.1. Thông tin chi tiết các thuộc tính

STT	Thuộc tính	Ý nghĩa	Kiểu dữ liệu
1	Address	Địa chỉ bất động sản	String
2	Area	Diện tích nhà (m ²)	Float
3	Frontage	Mặt tiền (m)	Float
4	Access Road	Độ rộng đường vào (m)	Float
5	House direction	Hướng nhà	String
6	Balcony direction	Hướng ban công	String
7	Floors	Số tầng	Integer
8	Bedrooms	Số phòng ngủ	Integer
9	Bathrooms	Số phòng tắm	Integer
10	Legal status	Tình trạng pháp lý	String
11	Furniture state	Tình trạng nội thất	String
12	Price	Giá nhà (tỷ đồng) - Target	Float

3.2. Khám phá dữ liệu (EDA)

Dữ liệu được phân tích bằng thống kê mô tả và trực quan hóa để hiểu cấu trúc của tập dữ liệu:

Thống kê mô tả:


CHƯƠNG 3. CHUẨN BỊ DỮ LIỆU

Bảng 3.2. Thống kê mô tả dữ liệu

Feature	Mean	Std	Min	25%	50%	75%	Max
Area	68.50	48.07	3.10	40.00	56.00	80.00	595.00
Frontage	5.36	4.35	1.00	4.00	4.50	5.00	77.00
Access Road	7.85	7.45	1.00	4.00	6.00	10.00	85.00
Floors	3.41	1.33	1.00	2.00	3.00	4.00	10.00
Bedrooms	3.51	1.31	1.00	3.00	3.00	4.00	9.00
Bathrooms	3.35	1.40	1.00	2.00	3.00	4.00	9.00
Price	5.87	2.21	1.00	4.20	5.90	7.50	11.50

Phân tích tương quan:

Dữ liệu cho thấy các thuộc tính số như diện tích, mặt tiền và số tầng có ảnh hưởng trực tiếp đến giá nhà. Trong khi đó, các đặc trưng categorical như hướng nhà, hướng ban công, tình trạng pháp lý và tình trạng nội thất cũng đóng vai trò quan trọng trong việc mô tả giá trị bất động sản.




Hình 3.2. Heatmap ma trận tương quan giữa các đặc trưng

Phân phối giá nhà (Price):

CHƯƠNG 3. CHUẨN BỊ DỮ LIỆU

Biến mục tiêu Price có giá trị trung bình khoảng 5.87 tỷ đồng, độ lệch chuẩn khoảng 2.21 tỷ đồng, và phân bố tập trung chủ yếu trong khoảng 4 đến 8 tỷ đồng. Chính vì vậy, dữ liệu có độ biến thiên không nhỏ và cần xử lý hợp lý trước khi đưa vào mô hình.



Hình 3.1. Biểu đồ Histogram/Boxplot cho phân phối giá nhà

3.3. Tiền xử lý dữ liệu

Quy trình tiền xử lý dữ liệu gồm các bước[5]:

- Kiểm tra và xử lý giá trị thiếu: Dataset Vietnam Housing Dataset 2024 có thể chứa giá trị thiếu và cần được xử lý bằng SimpleImputer trước khi đưa vào mô hình.
- Xử lý giá trị vô hạn: Các giá trị inf và -inf được thay bằng NaN và loại bỏ.
- Chia dữ liệu: Train/Test với tỷ lệ 80/20 (random_state=42).
- Chuẩn hóa: Sử dụng StandardScaler để chuẩn hóa dữ liệu về mean=0, std=1.

3.4. Xây dựng đặc trưng

Trong mô hình, các thuộc tính số như Area, Frontage, Access Road, Floors, Bedrooms, Bathrooms được đưa vào pipeline số, còn các trường categorical như House direction, Balcony direction, Legal status, Furniture state được mã hóa bằng OneHotEncoder. Cách làm này giúp mô hình Linear Regression có thể xử lý cả dữ liệu định lượng và định tính đồng thời.

CHƯƠNG 4. XÂY DỰNG MÔ HÌNH

4.1. Giới thiệu mô hình

Đề tài xây dựng một pipeline hồi quy tuyến tính (Linear Regression) để dự đoán giá nhà Việt Nam. Mô hình được triển khai trên tập dữ liệu Vietnam Housing Dataset 2024 với các feature số và categorical được tiền xử lý bằng ColumnTransformer của scikit-learn.

Ngoài ra, kỹ thuật Hyperparameter Tuning với GridSearchCV được áp dụng cho Random Forest để tối ưu hiệu suất[5].

4.2. Quy trình huấn luyện mô hình

Quy trình huấn luyện gồm 7 bước:

Bước 1: Tải dữ liệu Vietnam Housing Dataset 2024 từ file CSV.

Bước 2: Xử lý dữ liệu - loại bỏ các giá trị inf, NaN.

Bước 3: Chia dữ liệu thành tập Train (80%) và Test (20%).

Bước 4: Chuẩn hóa dữ liệu bằng StandardScaler.

Bước 5: Huấn luyện từng mô hình trên tập Train.

Bước 6: Đánh giá trên tập Test với các metrics RMSE, R^2 , MAE.

Bước 7: Lưu mô hình tốt nhất ra file .pkl và hiển thị kết quả trên Dashboard.

4.3. Ví dụ minh họa từng bước quy trình huấn luyện mô hình

Đầu vào: 8 đặc trưng đã chuẩn hóa của 16,512 mẫu train.

Quá trình: Linear Regression tìm hệ số w tối ưu bằng phương pháp Ordinary Least Squares (OLS), tối thiểu hóa tổng bình phương sai số: $\min ||Xw - y||^2$.

Đầu ra: Vector hệ số w (8 hệ số) và bias w_0 .

Dự đoán: Với dữ liệu mới, tính $\hat{y} = X_{\text{test}} @ w + w_0$.

4.4. Mô hình tự cài đặt

Linear Regression được cài đặt thủ công bằng công thức Normal Equation[8]: $w = (X^T X)^{-1} X^T y$. Việc cài đặt thủ công giúp hiểu rõ cơ chế hoạt động của thuật toán.

Mã nguồn cài đặt thủ công (minh họa):

```
class LinearRegressionManual:

    def fit(self, X, y):

        X_b = np.c_[np.ones((X.shape[0], 1)), X]

        self.w = np.linalg.inv(X_b.T @ X_b) @ X_b.T @ y

    def predict(self, X):

        X_b = np.c_[np.ones((X.shape[0], 1)), X]

        return X_b @ self.w
```

Mô hình tự cài đặt được kiểm tra trên cùng bộ dữ liệu và cho kết quả tương đương với thư viện scikit-learn (sai số $\sim 1e-15$) [5].

4.5. Mô hình cài đặt bằng thư viện

Các mô hình được cài đặt bằng thư viện scikit-learn với các tham số mặc định[5]:

```
LinearRegression()

Ridge(alpha=1.0)

Lasso(alpha=0.01)

DecisionTreeRegressor(max_depth=10, random_state=42)

RandomForestRegressor(n_estimators=100, random_state=42, n_jobs=-1)

GradientBoostingRegressor(n_estimators=100, random_state=42)

KNeighborsRegressor(n_neighbors=5)
```

Ngoài ra, GridSearchCV được sử dụng để tìm tham số tối ưu cho Random Forest:

```
Grid: n_estimators=[50, 100, 200], max_depth=[10, 15, 20, None],
min_samples_split=[2, 5, 10], min_samples_leaf=[1, 2, 4]
```

Kết quả tốt nhất: n_estimators=200, max_depth=20, min_samples_split=2, min_samples_leaf=1

CHƯƠNG 5. THỰC NGHIỆM VÀ ĐÁNH GIÁ

5.1. Kết quả huấn luyện

Kết quả model Linear Regression ban đầu (từ `train_model.py`):

Bảng 5.1. Kết quả model Linear Regression ban đầu

Metric	Giá trị
RMSE	1.9734
R^2	0.2013
Train samples	24,183
Test samples	6,046

Đánh giá này cho thấy mô hình Linear Regression đang hoạt động như một baseline khá đơn giản trên dữ liệu thực tế. RMSE đạt khoảng 1.97 tỷ đồng và R^2 đạt 0.2013, nghĩa là mô hình giải thích được khoảng 20.13% phương sai của biến mục tiêu. Đây là kết quả phù hợp với mục tiêu của đề án học tập, trong đó trọng tâm là hiểu rõ quy trình mô hình hóa và triển khai pipeline hồi quy tuyến tính.

5.2. Nhận xét

Từ kết quả thực nghiệm, có thể rút ra các nhận xét sau:

- Mô hình Linear Regression đã được triển khai thành công trên tập dữ liệu Việt Nam với pipeline tiền xử lý phù hợp cho feature số và categorical.
- Mức độ giải thích của mô hình hiện tại còn giới hạn, phản ánh rằng dữ liệu bất động sản Việt Nam có thể chứa nhiều yếu tố phi tuyến và mối quan hệ phức tạp hơn so với mô hình tuyến tính đơn giản.
- Dữ liệu hiện tại có nhiều đặc trưng kiểu categorical và không đồng nhất về chất lượng, do đó việc cải thiện mô hình cần tập trung vào feature engineering và khám phá thêm các biến ảnh hưởng.
- Trong bối cảnh đề án này, mô hình Linear Regression vẫn là lựa chọn hợp lý vì dễ diễn giải, dễ triển khai vào giao diện Streamlit và phù hợp với yêu cầu học tập của đề tài.

CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1. Kết quả đạt được

Sau quá trình nghiên cứu và thực hiện, đề tài đã đạt được các kết quả sau:

- Xây dựng thành công hệ thống dự đoán giá nhà Việt Nam với Linear Regression trên dataset Vietnam Housing Dataset 2024 và preprocessing cho feature số/categorical.
- Xây dựng Dashboard Streamlit trực quan với các biểu đồ Plotly [10] với thiết kế chuyên nghiệp cho phép nhập thông tin và nhận kết quả dự đoán tức thì. Thiết kế pipeline tiền xử lý dữ liệu phù hợp cho feature số và categorical, bao gồm imputer, scaler và one-hot encoding.
- Tạo ra ứng dụng web Streamlit cho phép người dùng nhập thông tin bất động sản và nhận kết quả dự đoán trực tiếp.
- Đánh giá mô hình bằng các chỉ số RMSE và R^2 , đồng thời lưu trữ mô hình dưới dạng file .pkl để tái sử dụng.
- Tạo file run.py cho phép khởi chạy toàn bộ hệ thống chỉ với 1 câu lệnh, thuận tiện cho người dùng.
- Đẩy toàn bộ mã nguồn lên GitHub để quản lý phiên bản và chia sẻ với cộng đồng.

6.2. Hạn chế của đề tài

Bên cạnh những kết quả đạt được, đề tài còn một số hạn chế:

- Chưa thu thập dữ liệu thực tế tại thị trường Việt Nam để xây dựng mô hình dự đoán phù hợp với điều kiện trong nước.
- Chưa tích hợp các mô hình Deep Learning hoặc các thuật toán nâng cao như XGBoost, LightGBM. Mô hình đang sử dụng là Linear Regression đơn giản, nên khả năng nắm bắt mối quan hệ phi tuyến giữa các biến còn hạn chế.
- Dataset có nhiều đặc trưng categorical và các giá trị thiếu, nên cần thêm feature engineering để cải thiện chất lượng dự đoán.
- Hiện tại, dashboard vẫn còn đơn giản và chưa tích hợp đầy đủ các công cụ phân tích nâng cao.
- Chưa hỗ trợ xử lý dữ liệu thời gian thực (real-time prediction) và cập nhật mô hình tự động.

6.3. Hướng phát triển trong tương lai

Để hoàn thiện hệ thống, các hướng phát triển trong tương lai bao gồm:

- Bổ sung thêm các thuật toán nâng cao như XGBoost, LightGBM, CatBoost và các mô hình Deep Learning (MLP, LSTM).
- Khảo sát và bổ sung thêm các biến đặc trưng mới để tăng độ chính xác của mô hình.
- Nâng cấp dashboard với thêm biểu đồ, thống kê mô tả và tính năng nhập dữ liệu thuận tiện hơn.
- Tích hợp API để có thể triển khai web app lên cloud (Streamlit Cloud, AWS, GCP) để truy cập từ internet.
- Phát triển cơ chế tự động cập nhật dữ liệu và retrain model định kỳ.

TÀI LIỆU THAM KHẢO

- [1] D. Harrison and D. L. Rubinfeld, "Hedonic housing prices and the demand for clean air," *Journal of Environmental Economics and Management*, vol. 5, no. 1, pp. 81–102, 1978.
- [2] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [3] J. H. Friedman, "Greedy function approximation: A gradient boosting machine," *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.
- [4] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, 2nd ed. New York, NY, USA: Springer, 2009.
- [5] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [6] E. A. Antipov and E. B. Pokrovskaya, "Mass appraisal of residential apartments: An application of Random forest for valuation and a CART-based approach for model diagnostics," *Expert Systems with Applications*, vol. 84, pp. 220–230, 2017.
- [7] S. Mullainathan and J. Spiess, "Machine learning: An applied econometric approach," *Journal of Economic Perspectives*, vol. 31, no. 2, pp. 87–106, 2017.
- [8] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*, 3rd ed. Sebastopol, CA, USA: O'Reilly Media, 2022.
- [9] Vietnam Housing Dataset 2024. (2024). Kaggle dataset. [Online]. Available: <https://www.kaggle.com/datasets/nguyentiennhan/vietnam-housing-dataset-2024>
- [10] Plotly Documentation. (2023). Plotly Technologies Inc. [Online]. Available: <https://plotly.com/python/>

PHỤ LỤC A. MÃ NGUỒN CHƯƠNG TRÌNH

A.1. Cài đặt từ đầu

Mã nguồn Linear Regression tự cài đặt:

```
import numpy as np
```

```
class LinearRegressionManual:
```

```
    """Linear Regression cài đặt bằng Normal Equation."""
```

```
    def __init__(self):
```

```
        self.w = None # weights
```

```
    def fit(self, X, y):
```

```
        """Huấn luyện mô hình bằng Normal Equation:  $w = (X^T X)^{-1} X^T y$ """
```

```
        X_b = np.c_[np.ones((X.shape[0], 1)), X] # Thêm bias
```

```
        self.w = np.linalg.inv(X_b.T @ X_b) @ X_b.T @ y
```

```
    def predict(self, X):
```

```
        """Dự đoán giá trị cho dữ liệu mới"""
```

```
        X_b = np.c_[np.ones((X.shape[0], 1)), X]
```

```
        return X_b @ self.w
```

A.2. Cài đặt bằng thư viện

Mã nguồn chính (train_model.py):

```
import json, numpy as np, joblib
```

```
from pathlib import Path
```

```
from sklearn.datasets import vietnam_housing_dataset.csv
```

```

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score

# Load & prepare data
data = vietnam_housing_dataset.csv(as_frame=True)
df = data.frame.copy().dropna()
X, y = df.drop(columns=["price", "address"]), df["price"].values

# Split & scale
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)
scaler = StandardScaler()
X_train_s = scaler.fit_transform(X_train)
X_test_s = scaler.transform(X_test)

# Train
model = LinearRegression()
model.fit(X_train_s, y_train)

# Evaluate
y_pred = model.predict(X_test_s)
rmse = np.sqrt(mean_squared_error(y_test, y_pred))
r2 = r2_score(y_test, y_pred)

```

```
# Save

joblib.dump(model, "model.pkl")
joblib.dump(scaler, "scaler.pkl")
with open("metrics.json", "w") as f:
    json.dump({"rmse": rmse, "r2": r2,
              "n_train": len(X_train),
              "n_test": len(X_test)}, f)
```


PHỤ LỤC B. PHÂN CÔNG CÔNG VIỆC

Bảng B-1. Phân công công việc của các thành viên trong nhóm

STT	Nội dung công việc	24DH190313 Phan Hoài Huy	24DH190093 Mai Thị Ngọc Lam
1	Thu thập, Tiền xử lý & Khám phá dữ liệu (EDA)	40%	60%
2	Cài đặt thuật toán & Huấn luyện mô hình	80%	20%
3	Xây dựng giao diện ứng dụng (Streamlit Dashboard)	20%	80%
4	Chạy thực nghiệm & Đánh giá kết quả mô hình	50%	50%
5	Tổng hợp tài liệu & Viết báo cáo Word	20%	80%
6	Thiết kế Slide & Thuyết trình	30%	70%